

个人作业1：桌游复杂度与玩家评分的量化关系分析

—— 基于 BoardGameGeek 数据

大数据处理技术课程 — 2025-2026第二学期

授课教师：周孟莹 | 数据集：BGG BoardGameGeek (TidyTuesday 2019)

环境就绪 - Python + Pandas + Matplotlib + Seaborn + Scikit-learn

课程：第三章 高维表格数据，第四章 时间序列分析

数据来源：BGG BoardGameGeek，来自 TidyTuesday 2019

数据集规模：10,532 行 × 22 列

列名：['game_id', 'description', 'image', 'max_players', 'max_playtime', 'min_age', 'min_players', 'min_playtime', 'name', 'playing_time', 'thumbnail', 'year_published', 'artist', 'category', 'compilation', 'designer', 'expansion', 'family', 'mechanic', 'publisher', 'average_rating', 'users_rated']

年份范围：1950 - 2016

有评分的游戏数量：10,532

	game_id	description	image	max_players	max_playtime	min_age
0	1	Die Macher is a game about seven sequential po...	//cf.geekdo-images.com/images/pic159509.jpg	5	240	
1	2	Dragonmaster is a trick-taking card game based...	//cf.geekdo-images.com/images/pic184174.jpg	4	30	
2	3	Part of the Knizia tile-laying trilogy, Samura...	//cf.geekdo-images.com/images/pic3211873.jpg	4	60	

3 rows × 22 columns

数据字典 (BGG TidyTuesday 2019)

列名	类型	说明	课程对应
game_id, name	ID/文本	游戏标识符与名称	—
year_published	年份	出版年份	第三章：序列数据

列名	类型	说明	课程对应
average_rating	浮点数 (1-10)	平均用户评分	连续数值型（目标变量）
users Rated	整数	评分人数	流行度指标
mechanic	文本（逗号分隔）	游戏机制标签	高维分类特征
category	文本（逗号分隔）	游戏类别	高维分类特征
playing_time	整数（分钟）	平均游戏时长	时长代理变量
min_players, max_players	整数	玩家人数范围	玩家配置
min_age	整数	最低推荐年龄	复杂度代理变量
designer, publisher, artist	文本	创作者元数据	分类变量

=== 数据清洗（第四章 pp.9-13）===





1. 过滤 users Rated >= 30: 10,532 -> 10,532 款游戏
2. 过滤有效出版年份: 10,532 -> 10,532 款游戏

=== 缺失值分析 ===

	缺失数量	缺失比例(%)
compilation	10122	96.11
expansion	7780	73.87
family	2808	26.66
artist	2773	26.33
mechanic	950	9.02
designer	126	1.20
category	94	0.89
publisher	3	0.03
thumbnail	1	0.01
image	1	0.01

剩余缺失值: 0
 评分异常值 (<1 或 >10): 0 行
 无效年份 (>2026): 0 行
 时长为 0 的记录: 350 行

最终数据集: 10,182 款游戏, 22 个字段

	game_id	description	image	max_players	max_playtime	min_age
0	1	Die Macher is a game about seven sequential po...		5	240	10
1	2	Dragonmaster is a trick-taking card game based...		4	30	10
2	3	Part of the Knizia tile-laying trilogy, Samura...		4	60	10
3	4	When you see the triangular box and the luxuri...		4	60	10
4	5	In Acquire, each player strategically invests ...		6	90	10

5 rows × 22 columns



=== 派生特征 ===

- log_users_rated: 流行度（对数尺度）
- time_bin: 时长类别
- age_bin: 推荐年龄类别
- mechanics_count: 机制数量（均值=2.4）
- player_range: 玩家人数弹性范围
- era: 出版时代

数据已就绪，可进行探索性分析。规模：(10182, 28)


步骤3：探索性数据分析（EDA）

遵循第三章“知识/洞察提取”范式（pp.4-5）


=== 评分分布 ===

均值：6.37，中位数：6.39





偏度：-0.301，峰度：0.495



评分分布图已保存至 `output/rating_distribution.png`



复杂度代理变量分析图已保存至 `output/complexity_analysis.png`





年度趋势图已保存至 `output/yearly_trends.png`

桌游行业指标：





年发行量：97/年 -> 629/年

平均评分：6.07 -> 6.99

平均机制数：1.9 -> 3.0



热门机制/类别图已保存至 [output/top_mechanics_categories.png](#)



时代对比图已保存至 [output/era_comparison.png](#)

=== Top-15 最高评分桌游 (评分人数 >= 5000) ===

	name	year_published	average_rating	usersRated	playing_time	mechanics
10001	Through the Ages: A New Story of Civilization	2015	8.74235	6888	240	Action Point Allocation, System, Auction/Bidding
9242	Pandemic Legacy: Season 1	2015	8.66878	17251	60	Action Point Allocation, System, Co-operative
10122	Star Wars: Rebellion	2016	8.54484	8142	240	Area Control, Influence, Movement
7615	War of the Ring (Second Edition)	2012	8.38424	6312	180	Area Control, Influence, Movement
9439	Terraforming Mars	2016	8.38065	8126	120	Card Drafting, Management, Placement
3885	Twilight Struggle	2005	8.35801	27008	180	Area Control, Influence, Campaign
9497	Scythe	2016	8.33346	14817	115	Area Control, Influence, Movement
10456	Mansions of Madness: Second Edition	2016	8.31660	6245	180	Area Movement, Cooperative Play, Roleplaying
7727	Terra Mystica	2012	8.29198	23684	150	Route/Network Building, Variable Order
9329	Star Wars: Imperial Assault	2014	8.20480	11017	120	Dice Rolling, Movement, Miniatures, Board
10046	Viticulture Essential Edition	2015	8.20053	5048	90	Management, Variable Phase Order, Worker Placement
9669	7 Wonders Duel	2015	8.19390	20088	30	Card Drafting, Cooperative
7374	Caverna: The Cave Farmers	2013	8.18155	16798	210	Tile Placement, Placement
9509	Blood Rage	2015	8.15840	13352	90	Action Point Allocation, System, Area Control


	name	year_published	average_rating	usersRated	playing_time	mechanics
7255	Mage Knight Board Game	2011	8.13794	18160	150	Card Draft operative Play,Deck

评分 9.0+ 的游戏: 1
评分 8.0-9.0 的游戏: 193
评分 7.0-8.0 的游戏: 2102
评分 7.0 以下的游戏: 7886

步骤4：特征工程与相关性分析

对应第三章“高维表格与特征维度” (p.31)

相关性矩阵：评分、复杂度代理变量与流行度




相关性热力图已保存至 `output/correlation_heatmap.png`

与 `average_rating` 的关键相关性:

`log_users_rated`: $r=0.353$ (+, 强相关)
`mechanics_count`: $r=0.317$ (+, 强相关)
`users_rated`: $r=0.235$ (+, 中等相关)
`min_age`: $r=0.192$ (+, 中等相关)
`min_players`: $r=-0.115$ (-, 弱相关)
`playing_time`: $r=0.058$ (+, 弱相关)
`max_players`: $r=-0.024$ (-, 弱相关)
`player_range`: $r=-0.020$ (-, 弱相关)

=== 研究问题1: 游戏复杂度 (游戏时长) 与评分是否相关? ===




游戏时长 vs 评分图已保存至 `output/playing_time_vs_rating.png`

游戏时长 vs 评分 Pearson $r = 0.058$

相关方向: 正相关

解读: 几乎无相关性。游戏质量并不取决于复杂度/时长。

=== 研究问题2: 与高评分相关的游戏机制 ===



机制与评分关系图已保存至 `output/mechanic_vs_rating.png`

评分最高的 Top-5 机制：

Simulation: 平均评分=6.93（样本量=554）

Area Control / Area Influence: 平均评分=6.83（样本量=791）

Action Point Allowance System: 平均评分=6.80（样本量=574）

Variable Player Powers: 平均评分=6.77（样本量=1,189）

Co-operative Play: 平均评分=6.75（样本量=462）

步骤5：核心发现

对应教学大纲“研究能力”目标2：“对结果进行统计处理，得出具有商业价值的工程结论”

=====

核心发现 - 桌游复杂度与玩家评分量化分析
大数据处理技术 - 个人作业1

=====

[发现1] 复杂度与评分关系：

游戏时长 vs 评分： $r = 0.058$

结论：游戏时长（复杂度代理变量）与评分几乎无相关性。

高质量游戏存在于所有复杂度层级——从简单到复杂。

[发现2] 桌游行业增长：

2000 年后发行的游戏： 7,272 / 10,182（占比 71%）

2000 年前平均评分： 6.09

2000 年后平均评分： 6.50

[发现3] 机制多样性与评分：

高机制多样性（Q4）平均评分： 6.68

低机制多样性（Q1）平均评分： 6.06

两者差异： 0.62

[发现4] 高分游戏画像（Top 5%）：

中位游戏时长： 120 分钟（全部： 45 分钟）

中位机制数量： 3（全部： 2）

中位最低年龄： 12（全部： 10）

中位出版年份： 2013（全部： 2007）

[发现5] 行业时代演变：

1980年以前： 787 款游戏，平均评分=5.95，平均机制数=1.8

1980-1995： 1,482 款游戏，平均评分=6.11，平均机制数=1.9

1995-2005： 2,353 款游戏，平均评分=6.12，平均机制数=2.1

2005-2015： 4,987 款游戏，平均评分=6.55，平均机制数=2.7

2015年以后： 573 款游戏，平均评分=7.11，平均机制数=3.1

=====

[作业2 方向]

* PCA: 100+ 机制 one-hot 编码 -> 2D/3D 机制空间（第三章 PCA）

* K-Means: 将桌游聚类为不同类型（第三章 聚类）

* 时间序列：检测评分趋势中的结构性断点（第四章）

=====

=== 数据处理流程总结 ===

原始数据： 2 万+款游戏， 22 个字段

清洗后： 10,182 款游戏

缺失值： 0（全部已处理）

派生特征： 7 个（log_users_rated, time_bin, age_bin, mechanics_count, player_range, era）

可视化图表： 8 张，已保存至 output/ 目录

课程知识点覆盖：

[OK] 第三章：表格数据、特征工程、高维分类特征

[OK] 第四章：数据清洗、缺失值处理、时间序列趋势

[OK] 教学大纲：多维数据建模、复合指标分解

已为作业2做好准备： PCA + 聚类 + 时间序列分析