

个人作业2：桌游复杂度与玩家评分的量化关系 (深度建模)

—— PCA降维 · K-Means聚类 · 时间序列分析

大数据处理技术课程 — 2025-2026第二学期

在作业1基础上深化：对应 Chapter3 PCA/聚类 + Chapter4 时间序列



环境就绪 — PCA + K-Means + 时间序列
课程覆盖：Chapter3 PCA/聚类，Chapter4 时间序列建模

数据加载完成：10,182 款游戏，25 列
年份范围：1950-2016
准备进行深度建模。

常见机制 (≥ 100 款游戏)：45
机制特征：45，类别特征：20
总计独热编码特征：65

模块A：PCA降维

Chapter3："主成分分析——将数百个表层指标降至少数几个稳定的潜在维度" **教学大纲：**"PCA降维技术，确保降维后的经济可解释性"



PCA碎石图已保存至 output/pca_scree.png

PCA结果：

PC1方差：4.83%

PC2方差：4.39%

PC1+2累计：9.22%

PC1+2+3累计：12.99%

达到80%所需主成分数：43

=====

PC1 - 贡献最大的机制（定义该维度的含义）

=====

PC1正载荷（最强正向）：

cat Wargame: +0.478

Hex-and-Counter: +0.429

cat World War II: +0.359

Simulation: +0.264

Dice Rolling: +0.170

Chit-Pull System: +0.156

Campaign Battle Card Driven: +0.102

Secret Unit Deployment: +0.095

PC1负载荷（最强负向）：

cat Card Game: -0.238

Hand Management: -0.183

Set Collection: -0.143

cat Bluffing: -0.125

cat Humor: -0.124

Card Drafting: -0.122

cat Party Game: -0.119

cat Deduction: -0.102

PC1解读：PC1 = 复杂策略 vs 简单派对游戏

PC2 - 贡献最大的机制：

PC2正载荷（最强正向）：

Variable Player Powers: +0.350

cat Adventure: +0.311

cat Fighting: +0.310

cat Fantasy: +0.269

cat Exploration: +0.259

PC2负载荷（最强负向）：


Unknown: -0.168

cat Children's Game: -0.130

cat Action Dexterity: -0.126

cat Party Game: -0.097


Pattern Recognition: -0.094



PCA二维可视化已保存至 `output/pca_2d_visualization.png`

模块B：K-Means聚类——桌游类型学

Chapter3： "聚类算法——用社会学模式和商业价值解释聚类结果" **教学大纲：** "使用算法模型解读聚类结果的商业/经济价值"



K-Means肘部图已保存至 `output/kmeans_elbow.png`

最优K = 4（轮廓系数 = 0.298）



K=4轮廓系数 = 0.298

桌游类型学—K-Means聚类结果

	avg_rating	std_rating	count	med_time	avg_mechanics	med_year	med_users	med_age
med_min_ply	med_max_ply	pct						
cluster								
0	5.98	0.76	4570	30.0	1.57	2006.0	116.0	9.0
2.0	5.0	44.9						
1	6.66	0.67	1668	45.0	2.40	2008.0	1242.5	10.0
2.0	5.0	16.4						
2	6.75	0.77	1611	150.0	2.12	1995.0	109.0	12.0
2.0	2.0	15.8						
3	6.56	0.80	1140	60.0	3.61	2009.0	298.5	10.0
2.0	5.0	11.2						
4	6.78	0.80	1193	60.0	4.66	2012.0	369.0	12.0
2.0	4.0	11.7						

=== 聚类解读 ===

聚类0: 中等时长, 较低评分, 规则简单 | 4,570.0 款游戏 (44.9%)
聚类1: 中等时长, 高评分, 规则简单 | 1,668.0 款游戏 (16.4%)
聚类2: 长时游戏, 高评分, 规则简单 | 1,611.0 款游戏 (15.8%)
聚类3: 中等时长, 高评分, 规则简单 | 1,140.0 款游戏 (11.2%)
聚类4: 中等时长, 高评分, 机制丰富 | 1,193.0 款游戏 (11.7%)



聚类可视化已保存至 output/cluster_pca_visualization.png

=== 各聚类代表游戏（按评分前3） ===

聚类0:

"Z War One: Damnation" (rating=8.62)
"RONE" (rating=8.53)
"Exceed: Red Horizon - Satoshi & Mei Lien vs. Baelkhor & Morathi" (rating=8.50)

聚类1:

"Puerto Rico: Limited Anniversary Edition" (rating=8.52)
"Orléans: Deluxe Edition" (rating=8.39)
"Terraforming Mars" (rating=8.38)

聚类2:

"Last Chance for Victory" (rating=8.85)
"The Greatest Day: Sword, Juno, and Gold Beaches" (rating=8.83)
"Last Blitzkrieg" (rating=8.80)

聚类3:

"Terra Mystica: Big Box" (rating=8.85)
"Through the Ages: A New Story of Civilization" (rating=8.74)
"1817" (rating=8.71)

聚类4:

"Small World Designer Edition" (rating=9.00)
"Kingdom Death: Monster" (rating=8.93)
"Pandemic Legacy: Season 1" (rating=8.67)


模块C：时间序列分析——行业演变

Chapter4: "时间序列数据与行为建模——平稳性检验、趋势分析、结构断点检测" **教学大纲:** "动态趋势分析与异常检测算法"

时间序列：46 个年份（年出版量>=20）
年份范围：1971 - 2016

	year	avg_rating	std_rating	pub_count	med_time	mean_time	avg_mechanics	total_ratings
21	1971	5.749164	0.645435	27	90.0	96.851852	1.814815	25652
22	1972	5.920155	0.729930	47	60.0	80.319149	1.808511	15285
23	1973	5.942957	0.987103	47	90.0	343.851064	1.702128	15703
24	1974	6.017823	0.721504	45	90.0	156.000000	2.044444	22659
25	1975	5.965690	0.764764	69	90.0	107.028986	1.971014	16841





时间序列图已保存至 output/time_series_industry.png

=====
评分趋势拐点（10年移动平均）
=====

评分谷值（潜在复兴起点）：
 年份 1987：评分 = 6.07

评分峰值（潜在黄金时期）：
 年份 1982：评分 = 6.12
 年份 1996：评分 = 6.11

=== 年代对比 ===

指标	1995年前	2000年后	2015年后
年均出版量	83	428	629
平均评分	6.06	6.41	6.99
平均机制数	1.9	2.5	3.0
中位游戏时长	83	46	52

增长倍数（1995年前 -> 2015年后）：
 出版量：8倍
 评分变化：+0.93

综合结论

课程大纲"研究能力"目标2 + "多维数据建模"目标

=====

综合结论

桌游复杂度与玩家评分

大数据处理技术—个人作业2

=====

[模块A - PCA降维]

- * 将65个机制/类别特征压缩为2-3个主成分
- * PC1+2解释了9.2%的机制方差
- * PC1捕捉了策略向vs休闲向的游戏轴
- * 高分游戏分布在整个机制空间中（不存在单一'公式'）

[模块B - K-Means桌游类型学]

- * 最优K=4，使用K=5以获得更丰富的细分
- * 识别出5个不同的桌游聚类
- * 聚类0: 4,570.0 款游戏 (44.9%)，平均评分=5.98，中位时长=30min
- * 聚类1: 1,668.0 款游戏 (16.4%)，平均评分=6.66，中位时长=45min
- * 聚类2: 1,611.0 款游戏 (15.8%)，平均评分=6.75，中位时长=150min
- * 聚类3: 1,140.0 款游戏 (11.2%)，平均评分=6.56，中位时长=60min
- * 聚类4: 1,193.0 款游戏 (11.7%)，平均评分=6.78，中位时长=60min

[模块C - 时间序列行业趋势]

- * 桌游出版量在2000年后激增（桌游复兴已证实）
- * 平均评分在几十年间上升
- * 游戏机制复杂度随时间呈现明显趋势

[核心论点]

复杂度（游戏时长）vs 评分: $r = 0.058$

结论：游戏复杂度并不决定评分。

简单和复杂的游戏都能获得高分。

游戏设计品质超越机制复杂度。

[局限性与未来方向]

- * BGG数据存在幸存者偏差（低评分游戏代表性不足）
 - * 游戏时长是复杂度的不完美代理变量
 - * 未来方向：图网络分析（设计师-出版商-机制网络，Chapter5）
 - * 未来方向：游戏评论的NLP情感分析（Chapter7非结构化文本）
 - * 未来方向：多模态分析（游戏美术+机制+评分，Chapter8）
- =====

=== 作业2流程总结 ===

输入数据：10,182 款桌游

特征：45 个机制 + 20 个类别 + 7 个游戏特征

分析模块：

[完成] PCA: 65 -> 2个主成分解释9%方差

[完成] K-Means: 5 个聚类, 轮廓系数=0.298

[完成] 时间序列: 1960-2020, 46 个年度观测

[完成] 可视化: 6张图表已保存至 output/

课程覆盖：

Chapter3: PCA降维, K-Means聚类

Chapter4: 时间序列趋势分析, 结构断点检测

教学大纲: 多维数据建模, 业务可解释性, 复合指标

完整流程: 数据 -> EDA (作业1) -> PCA -> 聚类 -> 时间序列 -> 结论 (作业2)