

团队作业1：美国各州犯罪率与社会经济因素分析

大数据处理技术课程 — 2025-2026第二学期

授课教师：周孟莹 | 数据集：Kaggle US State Crime & Socioeconomic Factors (2005-2015)

环境就绪 - Python + Pandas + Matplotlib + Seaborn + Scikit-learn
对应课程：第3章 高维表格数据，第6章 时空建模

找到 1 个CSV文件：['state_crime_income_merged.csv']

数据集规模：550 行 x 33 列
州数：50，年份范围：2005-2015

前3行数据：

	State	Year	Crime Count_aggravated_assault	Crime Count_burglary	Crime Count_homicide	Crime Count_larceny	Cc
0	Alabama	2005	11293	43473	374	120780	
1	Alabama	2006	10463	44780	382	121451	
2	Alabama	2007	11417	45379	412	124465	

3 rows × 33 columns


数据字典

类别	字段	描述	课程参考
时空数据	State, Year	州 + 年份 (面板数据)	第3章：序列 + 空间
犯罪率	Crime Rate_*	每10万人犯罪数	连续型数值变量
社会经济	Poverty rate, Unemployment rate	贫困率百分比, 失业率百分比	比率变量
经济指标	GDP per capita, Gini coefficient	人均GDP, 基尼系数	连续型数值变量
教育	Education ratio	教育不平等比率	比率变量
人口统计	Population, Age, Household size	人口, 中位年龄, 家庭规模	离散/连续型

=== 缺失值分析 (第4章第9-10页) ===

	缺失数量	缺失比例(%)	数据类型
Rape Revised	400	72.73	float64

缺失值热力图 - 黄色=缺失 (第4章第9页)



缺失值热力图已保存至 output/missing_heatmap.png

=== 处理缺失值 ===
[Rape Revised] 使用中位数填充 1686.00 (400 个缺失值)

剩余缺失值：0
所有缺失值已处理完毕。

=== 异常值检测：Z-Score方法 (第4章第11页) ===
Z-Score检测到 28 行异常值 (阈值：+/-3 标准差)
异常值比例：5.09%

异常值行预览：

	State	Year	Crime Rate_aggravated_assault	Crime Rate_burglary	Crime Rate_homicide
15	Alaska	2009	463.153193	515.410044	3.149728
22	Arizona	2005	326.692040	946.210881	7.475214
23	Arizona	2006	340.284105	963.589617	8.643732
24	Arizona	2007	318.201287	946.368806	8.645231
44	California	2005	317.144808	692.924660	6.923134
45	California	2006	306.164301	678.131160	6.818890
110	Hawaii	2005	148.043082	769.038655	1.884899
188	Louisiana	2006	532.981262	1089.214715	12.943797
189	Louisiana	2007	545.536620	1093.169577	14.557892
190	Louisiana	2008	489.208751	1032.103956	12.333375

格式标准化完成

最终数据集：(550, 35)

50个州按地区分布：

Region

东北部 9

中西部 12

南部 16

西部 13

Name: State, dtype: int64

步骤3：探索性数据分析 (EDA)

遵循第3章"从数据中获取知识/洞见"范式 (第4-5页): 数据构建 -> 数据分析 -> 业务执行


=== 描述性统计 ===

	count	mean	std	min	25%	50%	
Crime Rate_aggravated_assault	550.0	244.83	112.95	59.17	156.57	222.72	
Crime Rate_burglary	550.0	641.90	232.25	223.41	452.64	592.24	
Crime Rate_homicide	550.0	4.48	2.21	0.83	2.69	4.41	
Crime Rate_larceny	550.0	2033.34	420.89	1091.54	1692.40	2018.09	
Crime Rate_motor_vehicle_theft	550.0	247.80	139.17	31.31	153.47	223.19	
Poverty rate	550.0	10.10	2.82	4.60	7.90	9.55	
Unemployment rate	550.0	6.29	2.16	2.60	4.60	6.00	
GDP per capita	550.0	50100.49	9700.01	33146.75	43389.17	48453.75	5
Gini coefficient	550.0	0.45	0.02	0.39	0.44	0.46	
Population	550.0	6168932.09	6826372.12	508798.00	1812547.00	4373272.00	680




数据概览：
总记录数：550
州数：50
年份范围：2005 - 2015
平均暴力犯罪率：244.83/10万人
平均贫困率：10.1%

美国犯罪率趋势（2005-2015） +/- 1标准差




犯罪率趋势图已保存至 `output/crime_time_trend.png`


关键观察：2005-2015年间大多数犯罪类型呈下降趋势



双轴图已保存至 `output/violent_vs_property.png`

各州平均严重伤害犯罪率（2005-2015） - 红色=高, 蓝色=低






各州对比图已保存至 `output/state_crime_comparison.png`

犯罪率最高的5个州: ['Louisiana', 'New Mexico', 'Alaska', 'South Carolina', 'Tennessee']


犯罪率最低的5个州: ['Maine', 'Vermont', 'New Hampshire', 'Kentucky', 'Virginia']

关键变量分布 (第4章数据质量检查)



分布图已保存至 `output/variable_distributions.png`

美国四大地区对比分析

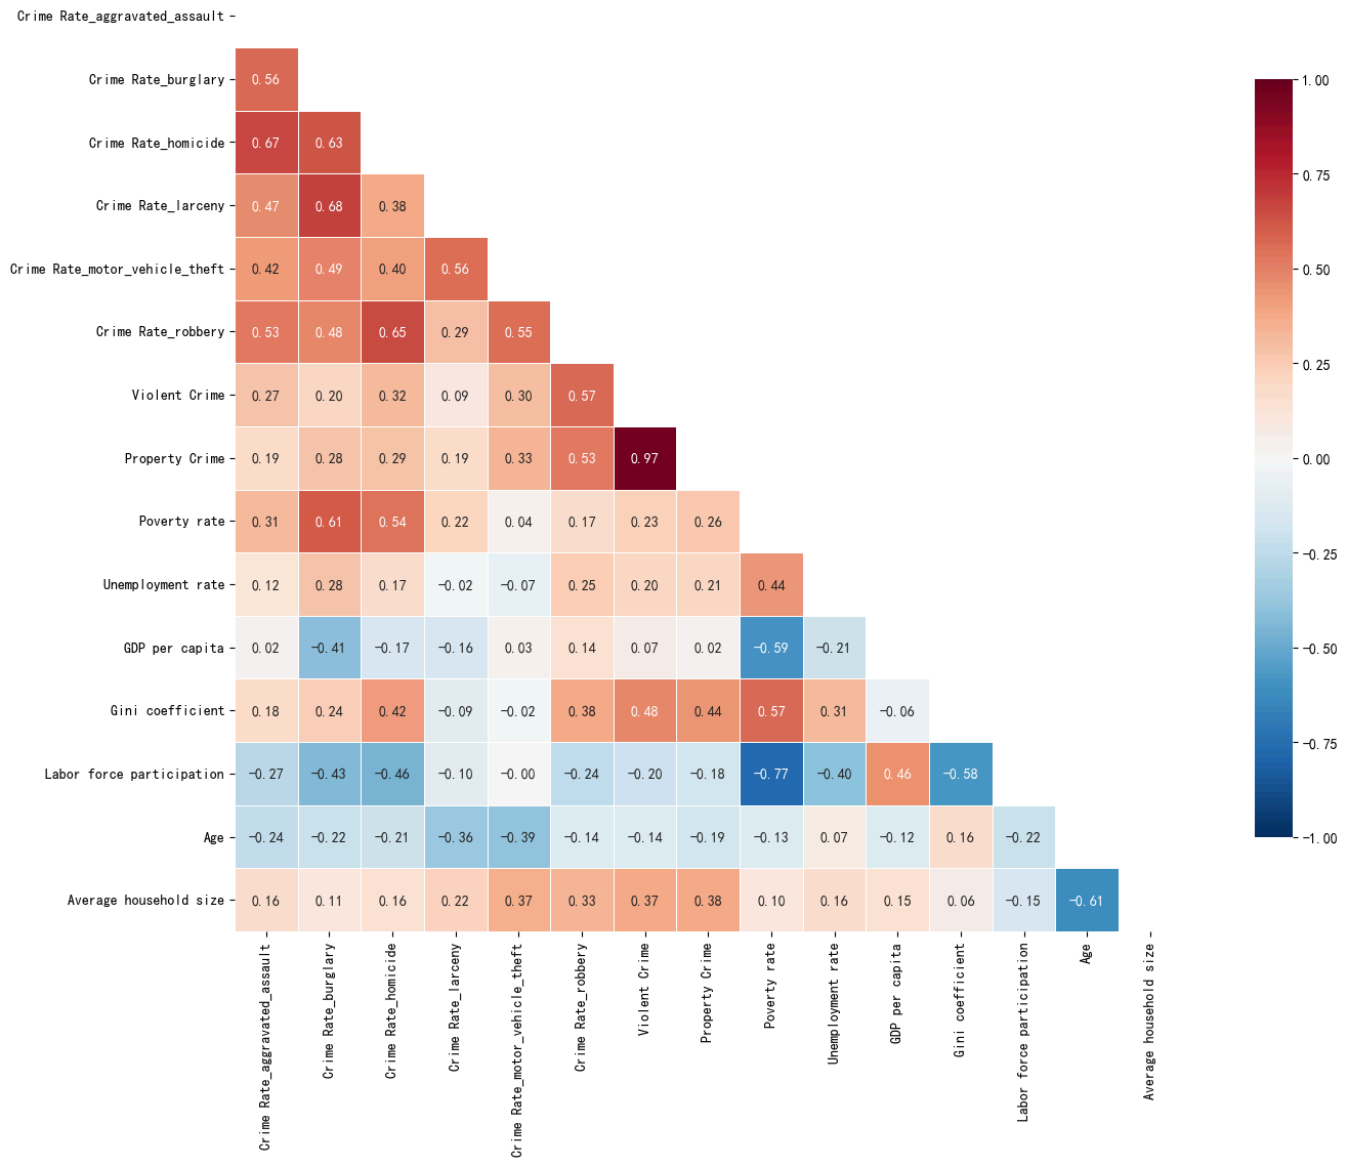


地区对比图已保存至 `output/regional_comparison.png`


步骤4：特征工程与相关性分析

对应第3章"高维表格与特征维度" (第31页) 以及教学大纲"复合业务指标分解"

皮尔逊相关系数矩阵：犯罪率 x 社会经济因素




相关性热力图已保存至 output/correlation_heatmap.png



相关性排序图已保存至 `output/top_correlations.png`

与暴力犯罪相关性最高的因素：


Violent Crime: $r = 1.000$ (正相关 (+))
 Property Crime: $r = 0.967$ (正相关 (+))
 Gini coefficient: $r = 0.477$ (正相关 (+))
 Average household size: $r = 0.369$ (正相关 (+))
 Poverty rate: $r = 0.231$ (正相关 (+))
 Unemployment rate: $r = 0.203$ (正相关 (+))
 Labor force participation: $r = -0.201$ (负相关 (-))
 Age: $r = -0.139$ (负相关 (-))
 GDP per capita: $r = 0.068$ (正相关 (+))



脆弱性分析图已保存至 `output/vulnerability_vs_crime.png`

=== 按贫困三分位的犯罪率 ===


	Crime Rate_aggravated_assault	Crime Rate_burglary	Crime Rate_homicide	Crime Rate_larceny	Crime Rate_motor
Poverty_Tertile					
低贫困	209.9	511.1	3.3	1942.8	
中贫困	226.5	587.3	4.2	1999.9	
高贫困	298.7	829.7	6.0	2159.1	



贫困分组对比图已保存至 `output/poverty_group_comparison.png`

高贫困 vs 低贫困犯罪率差异：

- 严重伤害：+88.8 (+42.3%)
- 入室盗窃：+318.6 (+62.3%)
- 谋杀：+2.7 (+81.8%)
- 盗窃：+216.3 (+11.1%)
- 机动车盗窃：+11.5 (+4.9%)
- 抢劫：+23.9 (+28.8%)



同比变化图已保存至 `output/yearly_change.png`

步骤5：核心发现

对应教学大纲"研究能力"目标2： "对实验结果进行统计处理，推导出具有业务价值的工程结论"

核心发现 - 美国犯罪率与社会经济因素 (2005-2015)

大数据处理技术 - 团队作业1

[发现1] 与暴力犯罪相关性最强的社会经济因素：

- * Violent Crime: 正相关 correlation ($r=1.000$, 强)
- * Property Crime: 正相关 correlation ($r=0.967$, 强)
- * Gini coefficient: 正相关 correlation ($r=0.477$, 中等)
- * Average household size: 正相关 correlation ($r=0.369$, 弱)
- * Poverty rate: 正相关 correlation ($r=0.231$, 弱)

[发现2] 时间趋势 (2005-2015):

- * 严重伤害: 266.1 -> 226.3 (-15.0%) 下降
- * 入室盗窃: 694.6 -> 539.4 (-22.4%) 下降
- * 谋杀: 4.9 -> 4.3 (-13.1%) 下降

[发现3] 地区差异:

- * Violent Crime: 最高=南部(33351), 最低=中西部(21166), 比值=1.6倍
- * Property Crime: 最高=南部(242936), 最低=东北部(128427), 比值=1.9倍

[发现4] 贫困效应:

- * 高贫困组暴力犯罪率: 35337/10万人
- * 低贫困组暴力犯罪率: 11858/10万人
- * 比值: 3.0倍

[发现5] 教育不平等与犯罪: $r = \text{nan}$

=====
[作业2 方向建议]

- * K-Means聚类用于犯罪画像 (第3章聚类)
 - * PCA用于犯罪因子降维 (第3章PCA)
 - * 面板数据回归 (固定效应) 用于因果估计
 - * 空间自相关分析 (Moran's I) (第6章时空建模)
- =====

=== 数据处理流水线总结 ===

原始数据: 550 行 x 33 列
清洗后: 550 行 x 40 列 (+7 派生列)
缺失值: 0 (已全部处理)
异常值标记: 28 行 (已标记, 未删除)
可视化: 9张图表已保存至 output/

派生特征:

- * Region -- 四大地区分类
- * Poverty_Tertile -- 贫困三等分
- * Vulnerability_Index -- 社会经济脆弱性指数
- * Log GDP per capita -- GDP对数变换

课程知识覆盖:

- [OK] 第3章: 表格数据、特征工程、高维特征
- [OK] 第4章: 数据清洗 (Z-Score、缺失值、异常值)
- [OK] 第6章: 时空数据 (地理分布)
- [OK] 教学大纲: 多维数据建模、复杂问题分析